Modelagem analítica: fundamentos

Avaliação de Desempenho (PC010029)

Prof. Dr. Helvecio Bezerra Leal Neto

Universidade Federal do Oeste do Pará

Aula 02 · 18 de agosto de 2026

Unidade I — Taxonomia das técnicas de avaliação de desempenho

Sumário

Parte 1

- O **estudo** de avaliação de desempenho: objetivos, limites e passos.
- **Métricas**: tempo de resposta, vazão e utilização; o **gargalo**.
- **Parâmetros** e **carga de trabalho** (real vs. sintética).
- A **taxonomia** das técnicas de avaliação.

Parte 2

- Técnicas: **aferição**, **simulação** e **híbrido** (visão geral).
- **Modelagem** — o foco de hoje: abstração, tipos física/matemática e o primeiro modelo analítico.
- Atividade prática.

Vocabulário essencial

- **AD**: Avaliação de Desempenho.
- **ASC**: Avaliação de Sistemas Computacionais.
- **Métrica**: critério mensurável que quantifica o desempenho.
- **Parâmetro**: variável de entrada que afeta o desempenho.
- **Workload**: carga de trabalho submetida ao sistema.
- **Modelo**: representação simplificada do sistema real.
- **Modelagem analítica** · **Simulação** · **Aferição**: as técnicas de avaliação.

Objetivos da aula

- Situar a **modelagem analítica** dentro da taxonomia das técnicas de avaliação de desempenho.
- Compreender o que é um **modelo** e por que abstraímos detalhes do sistema real.
- Distinguir modelagem **física** de **matemática**, comparando soluções **analíticas** e por **simulação**.
- Reconhecer **métricas**, **parâmetros** e **carga de trabalho**.
- Introduzir a **notação** base (λ, μ, ρ, N, T, X) que usaremos nas próximas aulas.

Esta é a 1ª de 2 aulas sobre modelagem analítica — hoje, os fundamentos.

Na aula anterior

Aula 01 — Apresentação da disciplina e plano de ensino:

- Apresentamos a **disciplina**, horários, sala e forma de avaliação.
- Percorremos a **ementa**: taxonomia, cadeias de Markov, teoria e redes de filas.
- Vimos o **cronograma** e os critérios de avaliação.
- Discutimos a **metodologia** e a **bibliografia** de referência.

O que é Avaliação de Desempenho?

Definição

Processo sistemático de **medição**, **modelagem** e **análise** para quantificar o comportamento e a eficiência de um sistema sob condições específicas de carga.

- **Desempenho** é um conceito *subjetivo*: depende do ponto de vista.
- A avaliação pode ser **a priori** (antes de existir) ou **a posteriori** (sistema pronto).
- Objetivo: *quantificar* e *comparar* o comportamento de forma objetiva.

Ex.: estimar por **modelo** a vazão de um servidor antes de construí-lo (**a priori**) vs. **medir** o tempo de resposta do sistema já em produção (**a posteriori**).

[Jain, 1991] · [Johnson, 2011]

Avaliação de Sistemas Computacionais (ASC)

Um sistema computacional recebe **requisições** (jobs, pacotes, pedidos) de **clientes** (usuários, softwares) para realizar um **serviço**.



Exemplos de sistemas a avaliar

- **Banco de dados**: consultas, inserções e alterações em tabelas.
- **Rede de computadores**: recebe pacotes numa interface e os encaminha a outra.
- **Servidor Web**: atende transações HTTP de milhares de usuários.
- **CPU / barramento**: instruções e transferências internas.

Pergunta: se você tivesse que decidir entre *comprar* um servidor mais caro ou *otimizar* o atual, como provaria (com números) qual vale mais a pena?

Passos de um estudo de avaliação de desempenho

1. **Definir objetivos e o sistema**: enunciar as metas do estudo e delimitar as fronteiras do sistema.
2. **Listar serviços e resultados**: relacionar os serviços oferecidos e os possíveis desfechos.
3. **Selecionar métricas**: escolher os critérios de comparação — em geral, velocidade, exatidão e disponibilidade.
4. **Listar parâmetros**: reunir tudo que afeta o desempenho (parâmetros de sistema e de carga de trabalho).
5. **Escolher a carga de trabalho e a técnica** de avaliação — e só então executar, analisar e apresentar.

[Jain, 1991, cap. 2]

Passo 1 — Objetivos e limites do sistema

Todo estudo começa **delimitando o alvo**: sem objetivos claros e uma fronteira bem definida, as decisões seguintes ficam sem rumo.

Definir os **objetivos**

- **Comparar** alternativas de projeto ou configuração.
- **Dimensionar** recursos (capacity planning).
- **Identificar gargalos** e ajustar (tuning).

Delimitar os **limites** (fronteira do sistema)

- O que está **dentro** vs. **fora** da análise.
- Componentes considerados e o **ambiente** externo.

Passo 2 — Listar serviços e resultados

Delimitado o sistema (passo anterior), o próximo passo é enumerar o que ele **faz** e os **desfechos possíveis** de cada requisição — base para escolher, adiante, as métricas certas.

Serviços: o que o sistema oferece

- Requisições que o sistema atende dentro de sua fronteira.
- Ex.: um servidor Web **responde páginas**; um banco de dados **executa consultas**.

Resultados: os desfechos de cada serviço

- **Sucesso**: o serviço é prestado corretamente.
- **Erro**: prestado de forma incorreta.
- **Indisponível**: não prestado (falha, recusa).

Definições básicas: métrica e parâmetro

Métrica

Critério usado para **quantificar o desempenho** do sistema — é o que se mede e compara.

- **Exemplos:** tempo de resposta de uma requisição, pacotes entregues por segundo, fração de uso da CPU.

Parâmetro

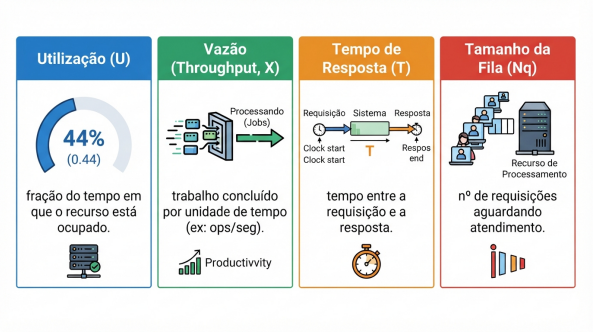
Característica do sistema ou da carga que **influencia a métrica** — é o que se varia no estudo.

- **Exemplos:** número de itens de um pedido, tipo de consulta SQL, largura de banda e MTU da rede.

Regra prática: escolha primeiro a métrica (o que avaliar) e depois os parâmetros com relação direta com ela. [Johnson, 2011, sec. 1.4]

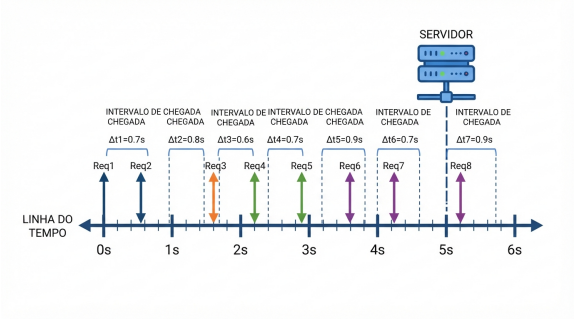
Métricas comuns de desempenho

- **Tempo de resposta** e **latência**: quanto o sistema demora para responder.
- **Vazão** (*throughput*): trabalho concluído por unidade de tempo.
- **Utilização**: fração do tempo em que cada recurso fica ocupado.
- **Tamanho da fila** (N_q): número de itens aguardando atendimento.
  (detalhado nas próximas unidades da disciplina)



Tempo de resposta e latência

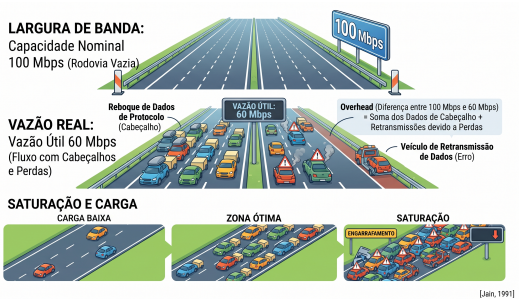
- **Tempo de resposta**: intervalo entre o envio da requisição e a chegada da resposta completa.
- **Latência**: atraso antes de o serviço começar (ex.: propagação na rede, espera em fila).
- É a métrica que o **usuário percebe** diretamente.
- **Exemplos:** tempo de carga de uma página, atraso de um pacote na rede.



[Johnson, 2011, sec. 1.5.3] · [Jain, 1991]

Vazão (throughput) e largura de banda

- **Largura de banda**: capacidade **nominal máxima** — todas as faixas da rodovia (teto teórico).
- **Vazão real**: trabalho **concluído** por tempo — os carros que de fato chegam ao destino (req./s, Mbps).
- **Overhead**: parte da capacidade que não vira trabalho útil — como faixas sempre ocupadas por comboios de escolta (cabeçalhos), carros que voltam e refazem o trajeto (retransmissões) e a espera para entrar na rodovia (contenção).
- **Saturação**: com tráfego demais surge o congestionamento, então a vazão pode estacionar (ou piorar).



As faixas da rodovia = largura de banda; os carros que passam = vazão real.

Utilização de recursos e gargalos

Utilização

É a fração do tempo em que o recurso fica **ocupado** durante a observação: utilização $= \dfrac{\text{tempo ocupado}}{\text{tempo total}}$ (de 0 a 100%).

Gargalo (*bottleneck*)

É o recurso de **maior utilização** no sistema — aquele que satura primeiro e, por isso, **limita o desempenho global**.

Exemplo: observamos um sistema por 60 s e medimos o tempo ocupado de cada recurso:

- **CPU:** ocupada 57 s $\Rightarrow$ $57/60 = \mathbf{95\%}$ de utilização.
- **Disco:** ocupado 24 s $\Rightarrow$ $24/60 = \mathbf{40\%}$ de utilização.
- Maior utilização é a da CPU $\Rightarrow$ **o gargalo é a CPU**; trocar o disco **não melhora** o desempenho.

Parâmetros: o que pode afetar a métrica

- Depois de escolher a **métrica**, liste tudo o que pode influenciá-la. Esses fatores de influência são os **parâmetros** do estudo, divididos em duas famílias:
- **Parâmetros de sistema** — o que vem do próprio sistema: velocidade da CPU, memória, largura de banda, algoritmo de escalonamento.
- **Parâmetros de carga** — o que vem das requisições: número de usuários, tamanho dos pedidos, mix de operações.

Nem todo parâmetro será testado: você fixa a maioria e **varia** só alguns. Ex.: num servidor web, fixa-se CPU e memória e varia-se apenas o **nº de usuários** (fator), com valores 10, 100 e 1000 (**níveis**).

Carga de trabalho (*workload*)

Definição

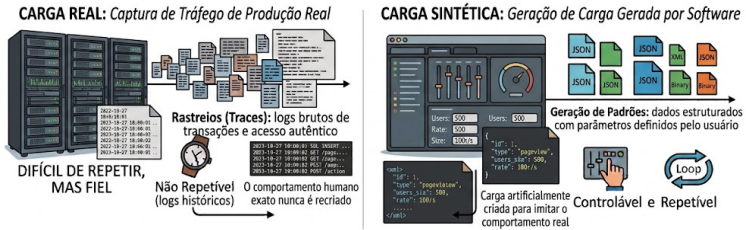
Carga é **tudo aquilo que o sistema precisa processar** durante a avaliação: o conjunto de tarefas, pedidos ou dados de entrada que chegam ao sistema. É o "trabalho" que colocamos sobre o sistema para **medir seu desempenho**.

- **Analogia:** para testar um carro, é o percurso que ele vai rodar; para o sistema, é a demanda que ele vai atender.
- **Exemplos:** consultas a um banco de dados, requisições HTTP a um servidor web, pacotes trafegando numa rede.
- Deve ser **representativa** do uso real, pois carga irreal leva a conclusões erradas.
- Junto com **métrica** e **parâmetros**, forma a base de qualquer estudo de desempenho.

[Johnson, 2011, sec. 1.4.3] · [Jain, 1991]

Cargas de trabalho: reais vs. sintéticas

- **Carga real**: registro do que o sistema em produção realmente processou (*traces*) — alta representatividade, mas difícil de controlar e reproduzir.
- **Carga sintética**: gerada artificialmente para imitar a real — controlável e **repetível**, via **sorteios aleatórios** de chegadas e tamanhos.
- A carga deve ser representativa **quantitativa** e **qualitativamente**: perfil errado leva a conclusões erradas.



Ponto de reflexão

Pergunta: um usuário reclama que o sistema "está lento". Como transformar essa frase em um **estudo de avaliação**: que *métrica* medir, que *parâmetros* variar e que *carga de trabalho* aplicar?

Do estudo à escolha da técnica

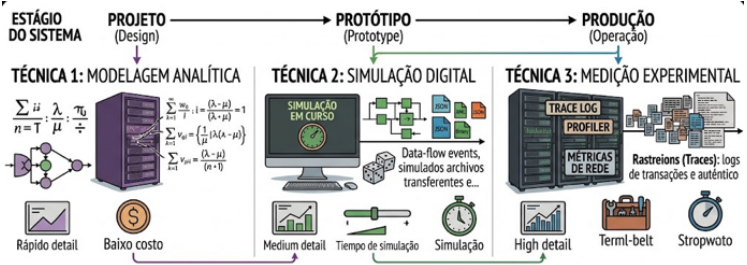
Com objetivos, métricas, parâmetros e carga definidos, resta **selecionar a(s) técnica(s)** de avaliação. Mas quais opções existem?

A ponte para a taxonomia

- Cada técnica responde à mesma pergunta de formas distintas.
- Elas diferem em **custo**, **precisão** e **momento** de uso.
- A escolha depende dos **objetivos** e **limites** definidos nos passos anteriores.

As três técnicas de avaliação

- Existem **três técnicas**: **modelagem**, **simulação** e **medição**.
- A escolha depende do **estágio do sistema**: projeto, protótipo ou produção.
- Há **critérios objetivos** para decidir, e não só a familiaridade do avaliador.
- Combinar duas ou mais técnicas (abordagem *híbrida*) aumenta a **confiança** nos resultados.



Taxonomia das técnicas de avaliação



Guarde este mapa: ele organiza toda a Parte 2 da aula.

Intervalo

Pausa de 10 minutos

Retomando: o mapa das técnicas

Chegamos à **taxonomia** das técnicas de avaliação de desempenho. Vamos relembrar o mapa e ver para onde a aula caminha:

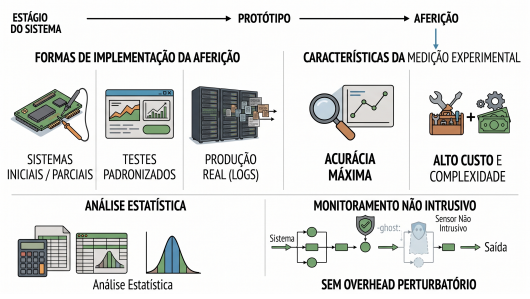
As três técnicas do nosso mapa

- **Aferição**: medir o sistema *real* (ou um protótipo).
- **Simulação**: *imitar* o sistema por um programa.
- **Modelagem**: representá-lo por uma *abstração matemática*.

Nos **dois próximos slides** passamos rapidamente por aferição e simulação — só para situá-las no mapa. O **foco de hoje**, a partir daí, é introduzir a **Modelagem Analítica**.

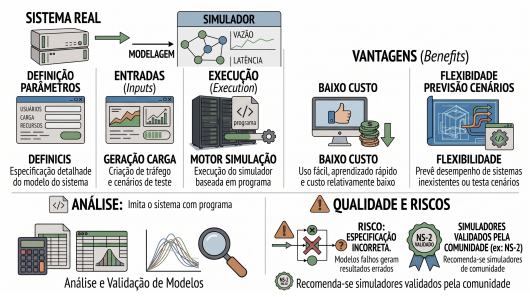
Aferição (Medição)

- Exige o sistema **existente** ou um **protótipo** (passível de experimentação).
- Resultados **mais precisos**, porém **maior custo** e complexidade.
- Requer tratamento **estatístico** adequado dos dados coletados.
- Formas: **prototipação**, **benchmark** e **coleta de dados**.
- A coleta deve ser **não intrusiva** para não distorcer o resultado (evitar que sobrecargas no monitoramento altere o comportamento do sistema).



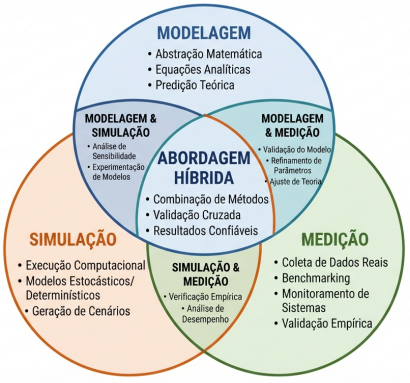
Simulação

- **Imita** o comportamento do sistema por meio de um programa.
- Muito usada pela **facilidade** de aprendizado e uso; **custo** relativamente baixo.
- Prevê o desempenho de sistema **ainda inexistente** ou testa cenários no existente.
- Risco: **modelos falhos**; especificação incorreta gera resultados errados.
- Recomenda-se usar simuladores **validados** pela comunidade (ex.: NS-2).



Híbrido

- Combina **duas ou mais** técnicas para validar e reforçar os resultados.
- **Combinações:**
  - Modelagem × Simulação
  - Modelagem × Medição
  - Simulação × Medição
- Ex.: medições reais servem de **entrada** para modelos analíticos.



Modelagem

Definição

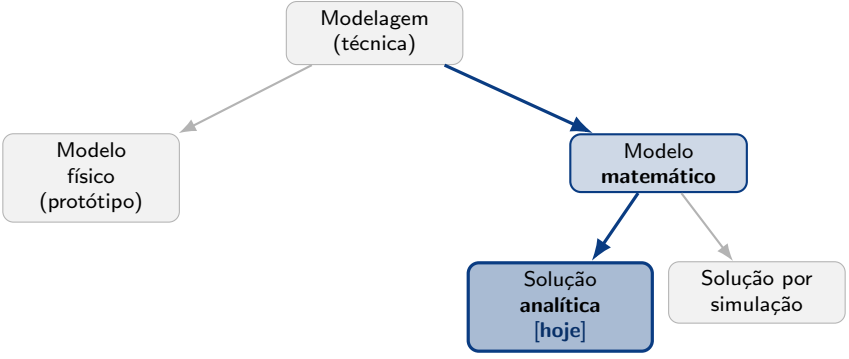
Criação de uma **representação abstrata e simplificada** do sistema real, capturando o comportamento essencial para a análise de desempenho e *eliminando* detalhes de baixo nível irrelevantes.

- Processo **mais simples** que as demais técnicas: descartamos o que não importa.
- Ideal quando o sistema **não existe** ou não pode ser perturbado (rede em produção).

[Johnson, 2011, cap. 1] · [Jain, 1991]

Onde estamos: tipos de modelo

A **modelagem** é uma das três técnicas de avaliação. Dentro dela, o modelo pode ser **físico** ou **matemático** — e o matemático é *resolvido* de forma analítica ou por simulação.



Não confundir: simulação e **aferição** são *técnicas* de avaliação (ao lado da modelagem), não tipos de modelo matemático.

Modelagem física vs. matemática

- **Física**: réplica em escala do sistema. Ex.: um *avião* em miniatura no túnel de vento.
- **Matemática**: representa o sistema por um **conjunto de equações**.
- **Resolução do modelo matemático**:
  - **Analítica**: solução exata obtida por dedução e fórmulas diretas.
  - **Por simulação**: solução aproximada por métodos numéricos/computacionais.

Exemplo simples de modelo analítico

Pressão: $P = \frac{F}{A}$ (F: força, A: área) — de duas variáveis obtém-se a terceira.

[Johnson, 2011, cap. 6]

Nomenclatura da modelagem analítica

- A modelagem analítica usa uma **notação padronizada**, quase sempre com **letras gregas** — herança da teoria de filas.
- Conhecer esses símbolos facilita ler artigos, livros e as fórmulas que veremos a seguir.

Símbolos que aparecem com frequência

- λ (*lambda*) — **taxa de chegada**: quantas requisições chegam por unidade de tempo.
- μ (*mi*) — **taxa de serviço**: quantas requisições o servidor consegue atender por unidade de tempo.
- ρ (*rô*) — **utilização**: fração de tempo em que o servidor permanece ocupado.

Um primeiro modelo analítico

Exemplo: Servidor Web

Como avaliar o suporte a tráfego sem testes caros? Modelamos duas taxas:

- **Taxa de chegada (λ):** demanda de acessos (ex.: 6 req/s)
- **Taxa de serviço (μ):** capacidade de processamento (ex.: 10 req/s)

Métricas e previsões derivadas:

- **Utilização (U):** $U = \frac{\lambda}{\mu} = \frac{6}{10} = 60\%$ (fração de tempo ocupado).
- **Previsão de falhas:** se a demanda dobrar ($\lambda = 12$), $U = \frac{\lambda}{\mu} = \frac{12}{10} = 120\% > 100\%$; como $\lambda = 12 > \mu = 10$, chegam 2 req/s a mais do que o servidor atende, a fila cresce e ocorrem *timeouts*.

Lei de Little

O que é?

A **Lei de Little** é uma regra matemática da **teoria das filas**: o número de itens em um sistema estável (L) é igual à taxa de chegada (λ) vezes o tempo médio que cada um passa no sistema (W).

- Vale para **qualquer sistema em equilíbrio**.

A relação fundamental

$$L = \lambda \cdot W$$

- L — número médio de requisições **no sistema**.
- λ — **taxa de chegada** (req./tempo).
- W — **tempo médio** no sistema.

Intuição: quanto mais requisições chegam (λ) e mais tempo cada uma permanece (W), mais lotado fica o sistema (L).

Lei de Little — exemplo prático

Cenário

Um **servidor web** recebe requisições a uma taxa constante e cada uma leva, em média, um certo tempo para ser atendida.

- $\lambda = 50$ req./s (taxa de chegada)
- $W = 0{,}2$ s (tempo médio no sistema)

Cálculo

$$L = \lambda \cdot W = 50 \times 0{,}2$$

$$\boxed{L = 10 \text{ requisições}}$$

- Em média, há **10 requisições** no servidor a qualquer instante.

E se o tempo dobrar?

Se $W = 0{,}4$ s (sistema mais lento), então $L = 50 \times 0{,}4 = 20$ requisições — o dobro de carga acumulada, sem mudar a taxa de chegada.

Limitações da modelagem analítica

- Pode se tornar **intratável** se o sistema for muito complexo.
- Exige **simplificações** (restrições) para manter a solução fechada.
- Simplificações em excesso podem tornar o modelo **irreal**.

Dilema central

Quanto mais *fiel* o modelo, mais *difícil* de resolver; quanto mais *simples*, mais distante da realidade.

[Bolch et al., 2006]

Quando escolher cada técnica?

Critério	Modelagem	Simulação	Aferição
Estágio do sistema	qualquer (mesmo inexistente)	qualquer	existente / protótipo
Custo	baixo	médio	alto
Precisão	moderada	moderada–alta	alta
Rapidez	alta	média	baixa
Complexidade de uso	alta (matemática)	média	alta

Adaptado de [Jain, 1991, cap. 3]

Atividade prática (na folha de papel em duplas)

Cenário simples

Um servidor web recebe **40 req/s** (taxa de chegada λ). Observou-se: CPU a 80%, disco a 30% e rede a 15% de utilização (U); **tempo médio no sistema** (W) de 0,5 s.

1. Aponte **uma métrica** e **um parâmetro** presentes no cenário.
2. Qual recurso é o **gargalo**? **Calcule a taxa de serviço** desse recurso.
3. Pela **Lei de Little**, **calcule o número médio de requisições** no sistema.
4. Para *prever* se o servidor aguenta o **dobro da carga** (80 req/s), qual **técnica** você usaria: aferição, simulação ou modelagem? Justifique.

Resolva na folha, não precisa entregar. Chamaremos **voluntários** para comentar e resolver as questões.

Resumo da aula

- **Passos do estudo**: objetivos e limites → métricas → parâmetros → carga de trabalho → técnica.
- **Métricas principais**: tempo de resposta/latência, vazão e utilização — o **gargalo** é o recurso mais utilizado.
- **Cargas de trabalho**: reais vs. sintéticas; a representatividade decide a validade do estudo.
- **Três técnicas**: aferição (precisa, cara), simulação (flexível) e modelagem (abstração — rápida e barata).
- **Modelagem**: representa o sistema de forma simplificada; a **analítica** usa equações e probabilidade — exata quando aplicável, mas exige simplificações.

Próxima aula

Aula 03 (25/08/2026) — Modelagem Analítica (Parte 2/2):

- Aprofundar a **modelagem analítica**: o que abstrair e quais **simplificações** assumir.
- As **etapas** de construção de um modelo: do sistema real ao conjunto de equações.
- Um **exemplo analítico** resolvido de ponta a ponta, com interpretação dos resultados.
- **Validar** o modelo: quando ele é fiel e quando as simplificações o tornam irreal.

Leitura recomendada

- **Johnson (2011)** — cap. 1 (técnicas e definições básicas): base desta aula.
- **Jain (1991)** — caps. 2 e 3 (metodologia; seleção de técnicas e métricas).
- **Allen (2014)** / **Tijms (2003)** — fundamentos probabilísticos.

Dúvidas?

Referências I


JAIN, R. *The Art of Computer Systems Performance Analysis*. John Wiley & Sons, 1991.


BOLCH, G.; GREINER, S.; DE MEER, H.; TRIVEDI, K. S. *Queueing Networks and Markov Chains*. 2. ed. Wiley & Sons, 2006.


TIJMS, H. C. *A First Course in Stochastic Models*. Wiley & Sons, 2003.


ALLEN, A. O. *Probability, Statistics, and Queueing Theory with Computer Science Applications*. 2. ed. Academic Press, 2014.


JOHNSON, T. M. S. M.; COUTINHO, M. M. *Avaliação de Desempenho de Sistemas Computacionais*. LTC/GEN, 2011.


MENASCÉ, D. A.; DOWDY, L. W.; ALMEIDA, V. A. F. *Performance by Design*. Prentice Hall, 2004.