Modelagem analítica: construção e validação

Avaliação de Desempenho — Aula 03

Prof. Dr. Helvecio Bezerra Leal Neto

Universidade Federal do Oeste do Pará

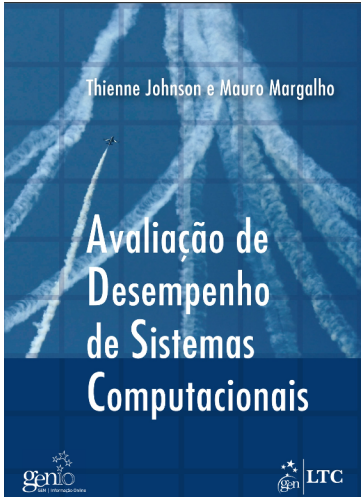
25/08/2026

Na aula anterior

- Três técnicas de avaliação: **aferição**, **simulação** e **modelagem analítica**
- Métricas: **utilização**, **vazão** e **tempo de resposta**
- Parâmetros do **sistema** $\times$ parâmetros da **carga de trabalho**

Hoje — Modelagem

Continuando com a **modelagem analítica**: hoje introduzimos os conceitos de **teoria de filas**, que modela chegadas e atendimentos **imprevisíveis**.



Fonte: [Johnson e Coutinho, 2011], cap. 2.

Vocabulário desta aula

Cliente	quem pede serviço: uma requisição, um pacote, uma tarefa
Centro de serviço	quem atende: CPU, disco, enlace de rede, impressora (m deles)
Fila	os clientes que já chegaram e ainda aguardam atendimento
Disciplina	a regra que escolhe qual cliente da fila entra em serviço
Chegada (λ)	o ritmo com que os clientes entram no sistema
Serviço (μ)	o ritmo com que um servidor conclui atendimentos
Vazão (X)	o ritmo com que as requisições *saem* prontas
Espera (w) *vs.* **resposta** (s)	tempo só na fila $\times$ tempo de fila mais atendimento ($s = w + x$)
Utilização (U)	a fração do tempo em que o servidor está ocupado
Estocástico	imprevisível caso a caso, mas regular na média
Estado (n) e p_n	quantos clientes há dentro agora; p_n é a **probabilidade de estado**: a chance de serem n
Intensidade de tráfego (ρ)	$\rho = \lambda/\mu$: a demanda em relação à capacidade; o **congestionamento**
Estabilidade	$\lambda < m\mu$ (ou seja, $\rho < 1$): a fila não cresce sem limite
Equilíbrio	o regime em que as probabilidades p_n param de mudar
Notação de Kendall	o código A/S/m/B/K/SD que resume uma fila, ex.: M/M/1
M/M/1	chegadas e serviço sem memória (exponenciais), um servidor
Nascimento e morte	o processo que sobe (chegada) e desce (saída) um degrau por vez

Cronograma

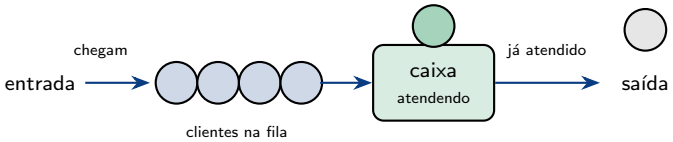
A aula segue as quatro seções do capítulo. A faixa abaixo aparece no início de cada uma, mostrando **onde estamos**:



1. **Filas**: o que são, onde aparecem, o que queremos estimar
2. **Sistemas de fluxo**: a família a que as filas pertencem, e por que computação cai no caso difícil
3. **Processo estocástico**: as duas distribuições que descrevem uma fila
4. **Fila única**: variáveis, relações e a notação de Kendall

2.1 — Filas fazem parte do dia a dia

Enfrentamos filas no supermercado, no parque de diversões, na farmácia. O exemplo mais comum é a **fila no banco**:



- Quando o funcionário está atendendo, **quem chega entra na fila e aguarda**
- Ao terminar, o cliente sai e **o primeiro da fila** se dirige ao caixa
- O mesmo padrão está no **check-in do aeroporto** e na **fila do lava a jato**

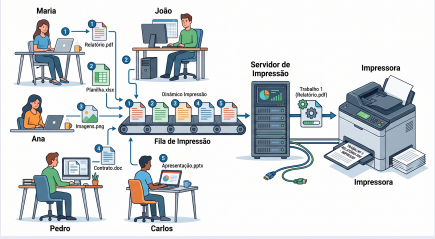
Fonte: [Johnson e Coutinho, 2011], cap. 2, p. 15.

2.1 — Filas nos sistemas computacionais

Nos sistemas computacionais usamos sistemas de filas o tempo todo:

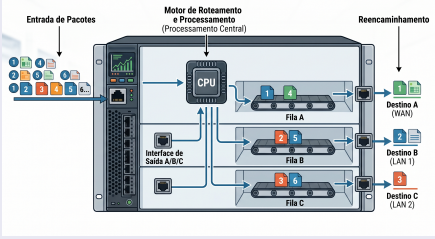
Impressão compartilhada

Vários usuários enviam arquivos; o servidor **processa um pedido por vez** na ordem da fila.



Roteador de rede

Pacotes chegam ao dispositivo; cada interface mantém uma **fila de pacotes** para envio.



O que vamos aprender a estimar neste capítulo

O **tempo de atendimento** de uma requisição · o **tempo de espera na fila** · o **número de clientes** dentro do sistema.

2.2 — Filas são um tipo de sistema de fluxo

2.1 Filas → 2.2 Sistemas de fluxo → 2.3 Processo estocástico → 2.4 Fila única → 2.5 Análise de fila única

Definição

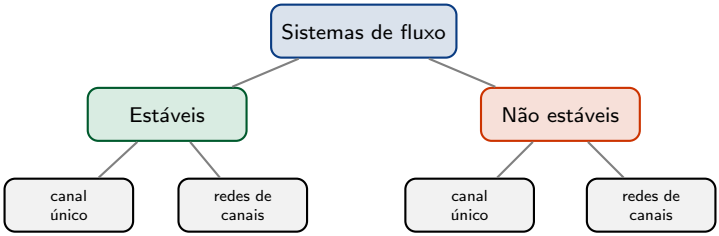
Um **sistema de fluxo** é qualquer sistema no qual **entidades** (dados, itens, pessoas ou recursos) fluem, se movem ou são transferidas através de **um ou mais canais de capacidade limitada**, de um ponto a outro no sistema.

Sistema	Entidade	Canal
Computador A transfere dados para o B	pacotes	link de rede
CPU transferindo bits entre memória e disco	bits	barramento da CPU

Capacidade limitada: cada canal transfere apenas *certa quantidade* de entidade em um dado intervalo, a uma **taxa finita** — limitada, nesses casos, pelo hardware da máquina.

Fonte: [Johnson e Coutinho, 2011], cap. 2, p. 16. Na literatura também se usa *commodity*.

2.2.1 — Classificação dos sistemas de fluxo



Estáveis

O fluxo passa de forma **previsível**: a quantidade que passa pelo canal é **constante e conhecida** no intervalo de observação. Também são constantes **quando** o fluxo chega e **quanto** demanda do canal.

Não estáveis

Fluxos **estocásticos** ou **randômicos**: as chegadas das mercadorias e o tamanho da demanda são **imprevisíveis**.

Fonte: [Johnson e Coutinho, 2011], cap. 2, pp. 16–17 (Figura 2.2).

2.2.1 — Canal único: onde a fila nasce

Num sistema de canal único, os itens entram por **um único canal** para serem processados (transferidos, executados, servidos) pelo canal de **taxa de serviço** (ou capacidade) μ. Sendo λ a **taxa de chegadas**:

Se $\mu > \lambda$

O sistema **consegue processar** os itens sem que ocorra sobrecarga do canal.

Se $\lambda > \mu$

O canal **não consegue processar**: a sobrecarga leva ao congestionamento, isto é, **filas de itens se formarão**.

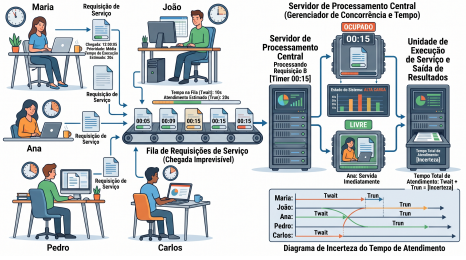
- Os sistemas **estáveis** de canal único atendem $\mu > \lambda$
- Nas **redes de canais** estáveis, vale $\mu > \lambda$ **em cada canal**
- **Guarde esta ideia**: ela reaparece na seção 2.4 como a **condição de estabilidade**, escrita com outras letras

2.2.1 — Por que computação cai no caso difícil

O caso dos sistemas computacionais

Usuários mandam requisições em **tempos imprevisíveis**, podendo encontrar o serviço solicitado **já ocupado** por requisições de outros usuários, ou **livre** para atender imediatamente. Portanto, essa incerteza **se estende ao tempo** em que a requisição demorará a ser atendida.

- Ou seja: **duas** fontes de incerteza — *quando* chega e *quanto* demora
- Sistemas não estáveis também se dividem em canal único e redes de canais
- Os fluxos randômicos **não são facilmente modelados** como os determinísticos



Técnica

A **teoria de filas** se propõe a ser uma ferramenta para resolver problemas relacionados aos **sistemas de fluxo randômicos**.

2.3 — Identificando o processo estocástico

Para analisar um sistema de fluxo é necessário **identificar o processo estocástico** que descreve três coisas: o **fluxo**, a **estrutura** e a **disciplina** do canal.

Mudança de vocabulário — daqui em diante

item $\longrightarrow$ **cliente**
canal $\longrightarrow$ **centro de serviço**

Processo estocástico

Coleção de variáveis aleatórias que representam a evolução de um sistema ao longo do tempo.

- "Cliente" é genérico: pode ser uma **requisição**, um **pacote**, um **job** ou uma pessoa
- Descrever o processo estocástico é descrever, com **distribuições de probabilidade**, quando os clientes chegam e quanto tempo levam sendo atendidos

2.3 — As duas distribuições: $A(t)$ e $B(x)$

Processo de chegada — $A(t)$

Descrito pela distribuição de probabilidade do **tempo entre chegadas**.

$$A(t) = P[\text{tempo entre chegadas} \leq t]$$

A taxa de chegadas depende da probabilidade de o tempo entre chegadas ser **menor** que t.

Tempo de serviço — $B(x)$

O **tempo de serviço** é a demanda que cada chegada faz ao canal: o tempo que um cliente demora sendo atendido.

$$B(x) = P[\text{tempo de serviço} \leq x]$$

Representa a probabilidade de o atendimento durar **menos** que x.

Hipótese fundamental

O **tempo entre chegadas** e o **tempo de serviço** são variáveis independentes: saber quanto durou um atendimento não informa quando chegará o próximo cliente.

2.3 — Exemplos: chegadas e serviço

Cenário: na mesma impressora, medimos duas coisas diferentes: tempo até a próxima chegada e tempo de serviço de cada trabalho.

Exemplo 1 — $A(t)$: chegadas

- Intervalos entre chegadas: 2, 5 e 2 segundos.
- Evento contado: nova chegada em até 3 segundos.
- Resultado observado: $A(3) = 2/3$.

$A(3)$ **fala do ritmo de entrada.**

Exemplo 2 — $B(x)$: serviço

- Tempos de impressão: 4, 1 e 3 segundos.
- Evento contado: serviço concluído em até 3 segundos.
- Resultado observado: $B(3) = 2/3$.

$B(3)$ **fala da duração do atendimento.**

Leitura prática

Os dois exemplos dão $2/3$, mas medem fenômenos diferentes: $A(t)$ descreve chegadas; $B(x)$ descreve tempos de serviço.

Pausa

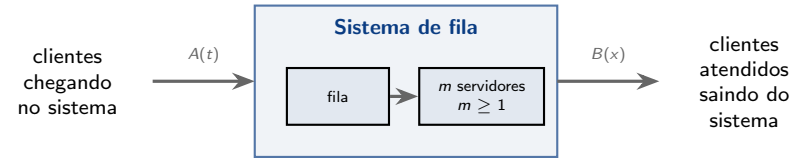
Intervalo de 10 minutos

Na volta: a caracterização completa de um sistema de fila única



2.4 — Caracterização dos sistemas de fila única

O sistema é composto de uma **linha de entrada**, o **sistema de fila** e uma **linha de saída**:

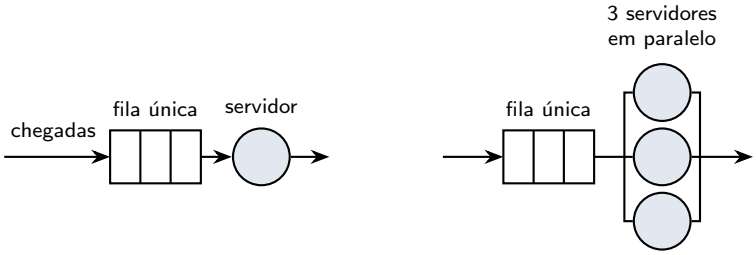


- Na entrada chegam os clientes (requisições, pacotes, *jobs*) com tempo arbitrário entre chegadas $A(t)$
- São atendidos em um tempo arbitrário de serviço $B(x)$ e liberados na linha de saída
- Dentro do sistema, a fila alimenta m **servidores**, com $m \geq 1$

2.4 — Uma fila, m servidores

A fila é **única**; m indica quantos servidores em paralelo recebem clientes dessa mesma fila.

O próximo cliente vai ao **primeiro servidor livre**; se todos estão ocupados, aguarda na fila comum.



(a) $m = 1$ (b) $m = 3$

$m = 1$: um atendimento por vez · $m = 3$: até três atendimentos simultâneos

2.4.1 — Variáveis: número de clientes

Var.	Significado
C_n	o n-ésimo cliente que entra no sistema
n_w	número de usuários **esperando** para serem atendidos (não inclui quem está sendo atendido)
n_s	número de usuários **em atendimento** dentro do centro de serviço
n	número de clientes **no sistema** num instante: inclui os que esperam *e* os que estão sendo atendidos

Definição: relação fundamental

A média do número total de clientes no sistema é a média dos que estão na fila mais a média dos que estão em atendimento:

$$E[n] = E[n_w] + E[n_s]$$

- $E[\cdot]$ denota o **valor esperado** (ou média).
- Como n_w não inclui quem está em atendimento (n_s), a fila é sempre menor que o total no sistema ($n_w < n$, quando $n_s > 0$).

2.4.1 — Variáveis: as duas taxas

Taxa de chegadas λ

Número médio de chegadas por unidade de tempo — o **inverso do tempo médio entre chegadas**:

$$\lambda = \frac{1}{E[t]}$$

Taxa de serviço μ

Quantos clientes **um servidor** atende por unidade de tempo — o **inverso do tempo médio de serviço**:

$$\mu = \frac{1}{E[x]} \qquad \text{com } m \text{ servidores: } m\mu$$

Exemplo, passo a passo

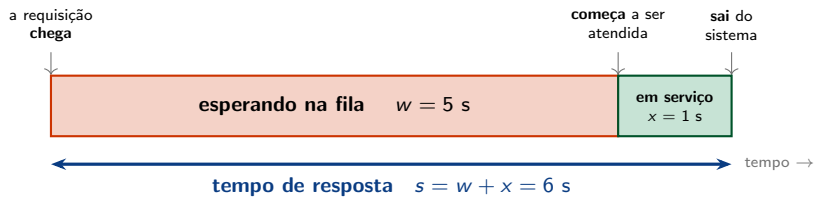
1. Observamos **8 chegadas** em **4 minutos**.
2. Tempo médio entre uma chegada e a seguinte:
$$E[t] = \frac{4 \text{ min}}{8 \text{ chegadas}} = 0{,}5 \text{ min}$$
3. Invertendo, chega-se à taxa:
$$\lambda = \frac{1}{E[t]} = \frac{1}{0{,}5} = \mathbf{2} \text{ clientes/min}$$

Exemplo, passo a passo

1. Cada servidor demora **2 s** por requisição: $E[x] = 2$ s.
2. Invertendo, a taxa de *um* servidor:
$$\mu = \frac{1}{E[x]} = \frac{1}{2} = \mathbf{0{,}5} \text{ req/s}$$
3. Pondo mais um servidor na mesma fila ($m = 2$):
$$m\mu = 2 \times 0{,}5 = \mathbf{1} \text{ req/s}$$

2.4.1 — Variáveis: os tempos

Os três tempos descrevem o ciclo de vida de **uma** requisição no sistema (da chegada à saída):



	Nome	Onde o cliente está
w	tempo de espera	**na fila**, aguardando
x	tempo de atendimento	**no centro de serviço**
s	tempo de resposta	**no sistema**: fila + serviço

A relação

$$E[s] = E[w] + E[x]$$

Vale para as **médias**. E x é o mesmo do slide anterior: $\mu = 1/E[x]$.

2.4.2 — Relacionamento entre as variáveis: Lei de Little

Se os usuários **não forem perdidos** por causa de *buffers* insuficientes, o número médio de usuários no sistema é a taxa de chegadas multiplicada pelo tempo médio de resposta:

No sistema inteiro

$$E[n] = \lambda \cdot E[s]$$

Só na fila

$$E[n_w] = \lambda \cdot E[w]$$

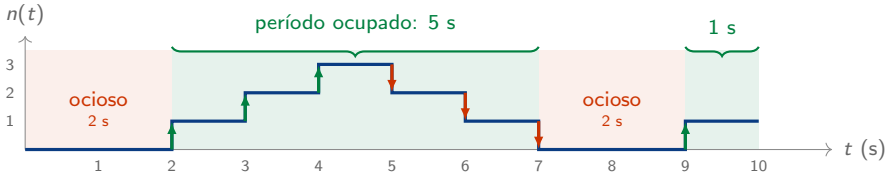
Como ler a lei

Se chegam λ clientes por segundo e cada um permanece $E[s]$ segundos, então a qualquer instante há em média $\lambda \cdot E[s]$ clientes lá dentro.

Repare que a **mesma forma** vale para a fila: basta trocar "permanece no sistema" por "espera na fila".

2.4.2 — Filmando o sistema: ocioso ou ocupado?

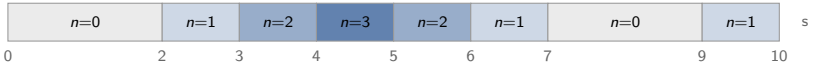
Câmera ligada: por 10 s anotamos $n(t)$, quantos clientes há **dentro do sistema** (fila + servidor).



- Cada ▲ é uma **chegada** (entra 1 cliente); cada ▼ é uma **saída** (sai 1 cliente).
- **Ocioso** ($n = 0$): servidor parado. **Ocupado** ($n \geq 1$): servidor atendendo.
- **Período ocupado**: trecho contínuo de atividade entre dois ociosos, **dois**: 2 a 7 s e 9 a 10 s.
- **Utilização** U: a fatia do tempo em que o servidor ficou ocupado $U = \dfrac{5+1}{10} = \mathbf{60\%}$.

2.4.2 — Do filme para p_n: a probabilidade de estado

O **mesmo filme** de 10 s, agora pintado pelo **estado** do sistema:



Definição: probabilidade de estado

p_n é a **probabilidade** de haver *exatamente n* clientes no sistema: a fração do tempo no estado n.

$$p_n = \frac{\text{tempo no estado } n}{\text{tempo total}}$$

Basta **somar o tempo** de cada cor:

estado	trechos do filme	tempo	p_n
$n = 0$	0–2 e 7–9	4 s	**40%**
$n = 1$	2–3, 6–7 e 9–10	3 s	**30%**
$n = 2$	3–4 e 5–6	2 s	**20%**
$n = 3$	4–5	1 s	**10%**

Fonte: [Johnson e Coutinho, 2011], cap. 2, p. 21.

Lendo: $p_0 = 4/10 = 0{,}40$: **vazio em 40% do tempo**.

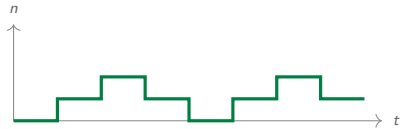
Cuidado: p_n mede **tempo**, não clientes.

As fatias fecham o filme inteiro:
$p_0 + p_1 + p_2 + \cdots = 1$.

Ocupado = não estar vazio: $U = 1 - p_0 = \mathbf{60\%}$.

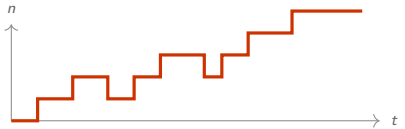
2.4.2 — Quando a fila explode: a condição de estabilidade

$\lambda < m\mu$ — **estável**



O sistema **esvazia** de tempos em tempos: a fila oscila, mas não foge.

$\lambda \geq m\mu$ — **instável**



Chega mais do que se consegue atender: o trabalho **se acumula** e a fila cresce para sempre.

A condição

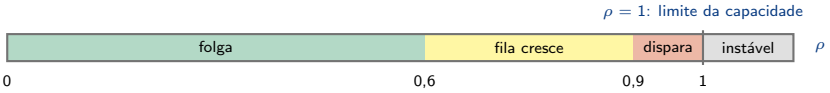
A taxa de chegadas tem de ser **menor** que a capacidade total de atendimento: $\lambda < m\mu$, com $m \geq 1$ servidores.

Essa condição vale para **fila infinita**: com **fila finita** não há instabilidade, quem não cabe é **recusado** (perda).

2.4.2 — ρ: a intensidade de tráfego e o congestionamento

ρ compara o que **chega** com o que o sistema **dá conta de atender**.

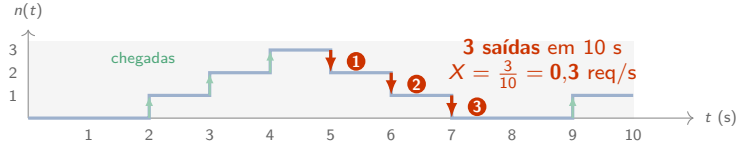
$$\rho = \frac{\text{taxa de chegadas}}{\text{taxa de serviço}} = \frac{\lambda}{\mu} \qquad \text{e, com } m \text{ servidores, } \quad \rho = \frac{\lambda}{m\mu}$$



- **Verde** ($\rho < 0{,}6$): servidor ocioso boa parte do tempo, espera quase nula.
- **Amarelo** ($0{,}6 \leq \rho < 0{,}9$): a fila se forma; a espera cresce mais rápido que a carga.
- **Vermelho** ($0{,}9 \leq \rho < 1$): perto da capacidade, um pequeno aumento de λ multiplica a espera.
- **Cinza** ($\rho \geq 1$): a fila cresce sem limite: não há regime estacionário.
- Estabilidade, em termos de ρ: $\rho < 1$.

2.4.2 — Vazão: um número, não uma série

Vazão (X): a **taxa de saídas**. No **filme do slide 21**, contemos quem **saiu pronto**:



Não se calcula a cada instante, nem para cada estado n

grandeza	tem um valor...	no filme acima
$n(t)$	por **instante**	muda o tempo todo: $0, 1, 2, 3, 2, 1, 0, 1$
p_n	por **estado** n	$p_0 = 40\%$, $p_1 = 30\%$, $p_2 = 20\%$, $p_3 = 10\%$
vazão X	**um só**, do sistema inteiro	3 saídas $\div$ 10 s $=$ **0,3** req/s

Janela curta engana: entraram 4 e saíram 3 (uma ficou dentro), então X ainda não bate com λ, vazão é **média de longo prazo**.

2.4.2 — Vazão: quem dita é a demanda

Em **regime**, chega-se à vazão por **dois caminhos**, e os dois dão o **mesmo** número:

Pelo que entra
nada se acumula: sai o mesmo que entra

$$\boxed{X = \lambda}$$

Pelo que o serviço entrega
$m\rho$ servidores ocupados, cada um a μ

$$\boxed{X = m\,\rho\,\mu}$$

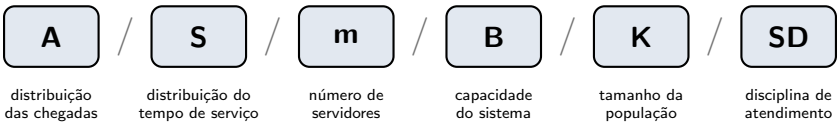
Exemplo — servidor de API, cada servidor atende $\mu = 40$ req/s

	servidores	chegam (λ)	capacidade ($m\mu$)	$\rho = \lambda/m\mu$	**vazão X**
A	$m = 2$	60 req/s	80 req/s	0,75	**60 req/s**
B	$m = 4$	60 req/s	160 req/s	0,375	**60 req/s**
C	$m = 2$	100 req/s	80 req/s	1,25	**80 req/s**

- **A**: os dois caminhos batem, $\lambda = 60$ e $m\rho\mu = 0{,}75 \times 80 = 60$ req/s.
- **A** $\rightarrow$ **B**: dobrar a capacidade **não** muda a vazão, cai só ρ, ou seja, a **espera**.
- **C**: $\rho > 1$, não há regime, a vazão **trava no teto** e o excedente vira fila sem fim ou **recusa**.

2.4.3 — Notação de Kendall

Em **1953**, D. G. Kendall criou uma notação de três parâmetros para caracterizar sistemas de fila. Hoje ela tem **seis**:



Regra prática

Os três últimos são **opcionais**. Se **B** é omitido, a capacidade é **ilimitada**; se **K** é omitido, a população é **infinita**; se **SD** é omitido, a disciplina é **FIFO**.

Fonte: [Johnson e Coutinho, 2011], cap. 2, p. 22.

2.4.3 — Os parâmetros A, S e m

A (distribuição do processo de chegadas de clientes ao sistema) e **S** (tempo de atendimento) usam as **mesmas** distribuições. As mais usadas são:

Código	O que significa	Exemplo típico
M	**Markoviana**: Poisson / exponencial, *sem memória*	Requisições HTTP chegando ao acaso
$\mathbf{E_k}$	**Erlang**: soma de k etapas exponenciais	Serviço em 3 fases: autenticar, consultar, responder
D	**Determinística**: tempo fixo	Sensor que envia leitura a cada 5 s
G	**Geral**: qualquer formato	Tempos medidos no log de produção
GI	**Geral independente**: G, e um tempo não influencia o próximo	Acessos de usuários que não se conhecem

m — número de servidores

De **um** a **infinitos** canais de atendimento. Com infinitos ninguém espera: é o **centro de atraso**.

Lendo na prática

M/M/1: chegadas de Poisson / serviço exponencial / um servidor. É a fila da próxima aula.

2.4.3 — Os parâmetros B e K

B — capacidade do sistema

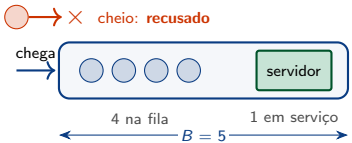
Máximo de clientes **dentro do sistema** ao mesmo tempo: os que estão **na fila** mais os que estão **em serviço**. Com o sistema cheio, quem chega é **recusado**.

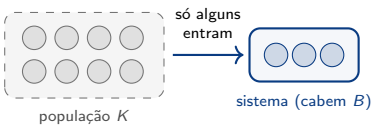
Omitido ⇒ capacidade **ilimitada**.

K — tamanho da população

Quem **poderia** usar o sistema, os possíveis usuários. *Ex.:* servidor acadêmico ⇒ alunos, funcionários e professores; servidor Web ⇒ população **teoricamente infinita**.

Omitido ⇒ população **infinita**.





K é quem *pode* chegar; B é quantos *cabem* lá dentro. Sempre $K \geq B \geq m$.

2.4.3 — O parâmetro SD: disciplina de atendimento

A ordem em que os clientes são atendidos após chegar à fila

Símbolo	Nome	Descrição
FIFO/FCFS	*First In First Out* / *First Come First Served*	Atendidos na **ordem em que chegam**
LIFO/LCFS	*Last In First Out* / *Last Come First Served*	Atendidos na **ordem reversa** à de chegada
SIRO	*Service In Random Order*	Atendidos em ordem **randômica**, sem considerar a ordem de chegada
RR	*Round Robin*	Cada cliente tem uma **fatia de tempo**; ao esgotá-la volta ao fim da fila, até completar o serviço
PS	*Processor Sharing*	RR com fatias **infinitesimais**: aparenta atender todas ao mesmo tempo, mas com o tempo de serviço aumentado
IS	*Infinite Server*	Tantos servidores que **nunca se forma fila**

Se o código da disciplina for omitido, assume-se FIFO.

2.5 — Quantas requisições estão aqui dentro agora?

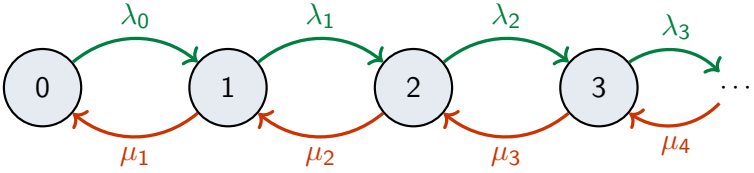


- Esse número n é o **estado** do sistema: para prever a fila, é tudo o que precisamos saber *agora*.
- Só duas coisas mudam o estado: uma **chegada** (**sobe** 1) ou um **fim de atendimento** (**desce** 1).
- Ele **nunca pula**: de 4 só se vai para 3 ou para 5, sempre de um em um.

2.5.1 — O processo de Nascimento e Morte

Pense em n como o tamanho de uma **população** que só muda de um em um:

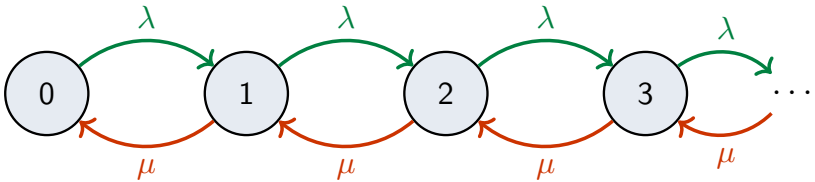
- **Nascimento** = chegada de um cliente: a população **aumenta** 1.
- **Morte** = fim de um atendimento: a população **diminui** 1.



- As transições só ligam **estados vizinhos**; cada estado pode ter taxas próprias λ_n e μ_n.
- Caso especial de **processo de Markov**: para prever o futuro basta o estado *atual*, não importa o caminho até ele.

Fonte: [Allen, 1978], cap. 4; [Kleinrock, 1976].

2.5.1 — M/M/1: o nascimento e morte mais simples

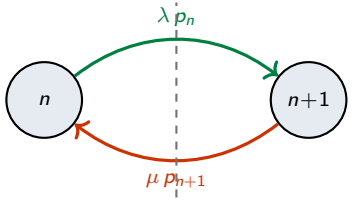


- **Nascimento = chegada de cliente**: o estado n é o número de clientes na fila; como as chegadas são de Poisson, $\lambda_n = \lambda$ em todo estado.
- **Morte = fim de um atendimento**: com um único servidor exponencial, basta haver alguém dentro para que $\mu_n = \mu$.
- **Taxas constantes**: nenhuma das duas depende de n — as setas valem iguais com a fila cheia ou quase vazia.

Fonte: [Johnson e Coutinho, 2011], §2.5.1.

2.5.1 — A regra que resolve o mapa

Seja p_n a **fração do tempo** em que há exatamente n requisições no sistema. Em equilíbrio, ao cortar o mapa em qualquer ponto, vale **o que entra = o que sai**:



A linha tracejada separa ≪até n≫ de ≪$n+1$ ou mais≫. Em equilíbrio, as duas travessias **empatam**:

$$\lambda\, p_n \;=\; \mu\, p_{n+1}$$

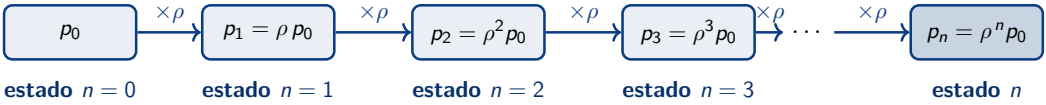
$$p_{n+1} \;=\; \rho\; p_n$$

com $\rho = \lambda/\mu$, a intensidade de tráfego da seção 2.4.

Por que $\lambda\, p_n$ e não só λ? Porque λ vale *enquanto* o sistema está em n, e ele só passa a fração p_n do tempo ali.

Fonte: [Allen, 1978], §4.3 (*flow in = flow out*); [Jain, 1991], §31.1.

2.5.1 — Cada degrau multiplica por ρ



De onde vem o $\times\rho$

- Corte entre n e $n+1$: o que sobe tem de igualar o que desce, $\lambda\, p_n = \mu\, p_{n+1}$.
- Logo $p_{n+1} = \dfrac{\lambda}{\mu}\, p_n = \rho\, p_n$, com $\rho = \lambda/\mu$.
- Vale em **todos** os cortes: aplicando desde o estado vazio, $p_n = \rho^n p_0$.

O que isso já nos diz

- As probabilidades caem em **progressão geométrica** de razão ρ.
- $\rho < 1$ é a condição de estabilidade: só assim a soma converge.
- Tudo ficou em função de p_0. Falta **uma** conta: normalizar $\sum_{n\geq 0} p_n = 1$ e descobrir quanto p_0 vale.

2.5.1 — A conta que fecha tudo: quanto vale p_0

As fatias de tempo somam o tempo todo:

$$p_0 + p_1 + p_2 + \cdots = 1$$

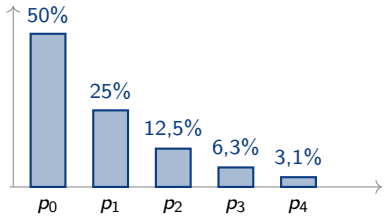
Trocando cada p_n por $\rho^n p_0$:

$$p_0 \left(1 + \rho + \rho^2 + \cdots\right) = 1$$

A soma vale $1/(1-\rho)$, logo:

$$\boxed{p_0 = 1 - \rho \quad \text{e} \quad p_n = (1-\rho)\,\rho^n}$$

Exemplo: $\rho = 0{,}5$ (o servidor recebe metade do que dá conta)



$p_0 = 1 - 0{,}5 = 0{,}5 \qquad p_1 = 0{,}5 \cdot 0{,}5 = 0{,}25$
$p_2 = 0{,}5 \cdot 0{,}5^2 = 0{,}125$ e assim por diante

Metade do tempo o sistema fica **vazio**.

Só existe resposta se $\rho < 1$ — senão a soma não fecha, e a fila cresce para sempre.

2.5.1 — Exemplo (I): quantas requisições

O enunciado — o que sabemos do sistema

Um **servidor web** em **fila única**, sem limite: a **M/M/1**. Dele sabemos:

quantas chegam	$\lambda = 50$ req/s	*a demanda*
quantas ele atende	$\mu = 100$ req/s	*a capacidade*
quanto leva cada uma	$1/\mu = 10$ ms	100 cabem em 1 s $\Rightarrow$ cada uma ocupa $1/100 = 0{,}01$ s

Passo 0 — a intensidade de tráfego: $\rho = \lambda/\mu = 50/100 = \mathbf{0{,}5}$ — o servidor usa **metade** da capacidade

1. **Quanto do tempo o servidor fica vazio?** $p_0 = 1 - \rho = 1 - 0{,}5 = \mathbf{50\%}$ do tempo.
2. **E trabalhando?** $U = 1 - p_0 = \rho = \mathbf{50\%}$ do tempo.
3. **Quantas requisições há dentro?** $E[n] = \rho/(1-\rho) = 0{,}5/0{,}5 = \mathbf{1}$ requisição.
4. **Quantas delas estão só esperando?** $E[n_w] = E[n] - U = 1 - 0{,}5 = \mathbf{0{,}5}$ requisição.
5. **Qual a chance de haver 3 ou mais?** $P(\geq 3) = \rho^3 = 0{,}5^3 = \mathbf{12{,}5\%}$.

2.5.1 — Exemplo (II): quanto tempo

O mesmo servidor: $\lambda = 50$ req/s, $\mu = 100$ req/s, $\rho = 0{,}5$, $1/\mu = 10$ ms.

6. **Quanto tempo a requisição fica dentro?**
   $E[s] = 1/[\mu(1-\rho)] = 1/[100\,(1-0{,}5)] = 1/50 = 0{,}02$ s = **20 ms**
7. **Quanto ela passa parada na fila?**
   $E[w] = E[s] - 1/\mu = 0{,}02 - 0{,}01 = 0{,}01$ s = **10 ms**

Confira pela Lei de Little: $E[n] = \lambda\, E[s] = 50 \cdot 0{,}02 = 1$ — o mesmo valor do passo 3.

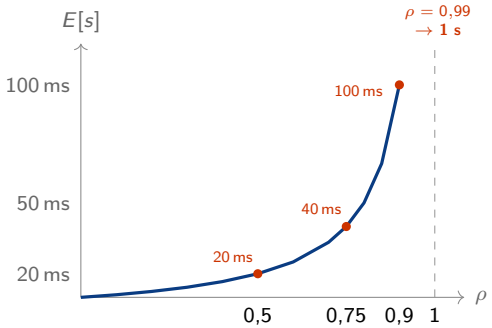


O servidor atende em 10 ms, mas a requisição sente 20 ms, e ele estava ocupado só **metade** do tempo.

Fonte: [Jain, 1991], §31.2; [Johnson e Coutinho, 2011], §2.5.1.

2.5.1 — Por que 99% de utilização é uma cilada

O mesmo servidor (atende em 10 ms). E se a demanda λ crescer?



chegam λ	ρ	$E[n]$	resposta $E[s]$
50 req/s	0,50	1 req.	**20 ms**
75 req/s	0,75	3 req.	**40 ms**
90 req/s	0,90	9 req.	**100 ms**
99 req/s	0,99	99 req.	**1 s**

$E[s] = 1/[\mu(1-\rho)] = (1/\mu)/(1-\rho)$: o atendimento $1/\mu$ **esticado** por $1/(1-\rho)$.

A demanda cresceu **menos que o dobro**, mas a resposta foi de 20 ms para **1 s — 50 vezes**.

Servidor 2× mais rápido não resolve: o que explode é a **espera**, não o atendimento.

Exercício em sala — o servidor Web

Enunciado

Um **servidor Web** conectado a um roteador recebe em média **3.600 requisições de páginas HTML por minuto**. Ele tem capacidade de atender, em média, a **80 requisições por segundo**. **Calcule todas as propriedades de fila** desse servidor.

O servidor tem **uma interface de rede**: todas as requisições chegam pela mesma entrada e aguardam em uma **fila interna**, sem limite de fila nem de população. $\Rightarrow$ é uma **M/M/1**.

Calcule, nesta ordem

1. λ, μ as duas taxas
2. ρ, U intensidade e utilização
3. p_0 nenhum usuário no sistema
4. p_5 cinco usuários no sistema
5. $P(\geq 5)$ cinco *ou mais* usuários
6. $P(\geq 1)$ um *ou mais* usuários
7. $E[s]$ tempo médio de resposta
8. $E[w]$ tempo médio de espera na fila
9. $E[n]$ número médio de usuários
10. $E[n_w]$ nº médio de requisições na fila

Em duplas, 30 minutos.

Resolução (I) — taxas, intensidade de tráfego e probabilidades

Passo 1 — as duas taxas

Chegadas: $\lambda = \dfrac{3600}{60} = \mathbf{60}$ req/s

Serviço: $\mu = \mathbf{80}$ req/s

As chegadas vêm por minuto e o serviço por segundo: antes de qualquer conta, as duas taxas têm de estar na **mesma unidade**.

Passo 2 — intensidade de tráfego e utilização

$$\rho = \frac{\lambda}{\mu} = \frac{60}{80} = \mathbf{0{,}75} \implies U = \mathbf{75\%}$$

$\rho < 1$: a fila é **estável**, e todo o resto do exercício sai deste único número. O servidor passa **75% do tempo ocupado** e 25% ocioso.

Passo 3 — as probabilidades de estado

Probabilidade de...	**Conta**	**Resposta**
nenhum usuário no sistema	$p_0 = 1 - \rho = 1 - 0{,}75$	**25%**
cinco usuários no sistema	$p_5 = (1-\rho)\,\rho^5 = 0{,}25 \cdot 0{,}75^5$	**5,9%**
cinco *ou mais* usuários no sistema	$P(\geq 5) = \rho^5 = 0{,}75^5$	**23,7%**
um *ou mais* usuários no sistema	$P(\geq 1) = \rho^1 = 0{,}75$	**75%**

Confira: $P(\geq 1)$ é exatamente a **utilização** — ter "um ou mais" é o mesmo que o servidor estar ocupado.

Resolução (II) — tempos e números

Passo 4 — os tempos e os números médios

Métrica	Conta	Resposta
Tempo médio de resposta $E[s]$	$1/[\mu(1-\rho)] = 1/[80\,(1-0{,}75)] = 1/20$	**0,05 s**
Tempo médio de espera na fila $E[w]$	$E[s] - 1/\mu = 0{,}05 - 0{,}0125$	**0,0375 s**
Número médio de usuários $E[n]$	$\rho/(1-\rho) = 0{,}75/0{,}25$	**3 req.**
Nº médio de requisições na fila $E[n_w]$	$E[n] - U = 3 - 0{,}75$	**2,25 req.**

O $1/\mu = 1/80 = 0{,}0125$ s é o **atendimento puro**: tirá-lo do tempo de resposta deixa só o que a requisição passou *parada na fila*. Do mesmo modo, $E[n_w] = E[n] - U$ tira de $E[n]$ a requisição que está sendo atendida (o mesmo que $\rho^2/(1-\rho) = 0{,}75^2/0{,}25 = 2{,}25$).

Confira (Little): $E[n] = \lambda\, E[s] = 60 \cdot 0{,}05 = 3$ — bate com $\rho/(1-\rho)$.

Leitura: o servidor tem folga (75%), mas cada requisição passa **3/4** do seu tempo de resposta parada na fila.

Antes de confiar no modelo: verificação e validação

"É M/M/1" é uma **hipótese**, não um fato observado. Daí duas perguntas **diferentes**:

Verificação — as contas estão certas?

Unidades convertidas, substituições corretas e as relações da aula **fechando entre si**: $E[n] = E[n_w] + E[n_s]$, $E[s] = E[w] + E[x]$, $E[n] = \lambda E[s]$. Conferência **interna** ao modelo.

Validação — é o sistema certo?

As distribuições, os parâmetros e a estrutura descrevem mesmo **aquele** sistema? Conferência **contra o mundo**: exige olhar o sistema real.

Um modelo verificado pode estar errado; um modelo não validado é só uma hipótese.

Três técnicas de validação

1. **Intuição de especialista** — quem conhece o sistema acha o resultado plausível?
2. **Medições no sistema real** — comparar previsto com medido
3. **Resultados teóricos** — conferir contra casos de solução conhecida

Fonte: [Jain, 1991], cap. 25.

Validando uma fila: parâmetro por parâmetro

A notação de Kendall dá o **roteiro de validação**: cada letra vira uma pergunta.

O que	A pergunta	Como responder
A e S	As chegadas são mesmo Poisson? O serviço é mesmo exponencial?	Levantar o **histograma** desses tempos no log
m, B, K, SD	O nº de servidores, o limite da fila e a ordem de atendimento batem com o real?	Ler a configuração: *threads*, *buffer*, escalonamento
λ e μ	Foram **medidos** ou **chutados**?	λ contando chegadas no log; μ cronometrando o atendimento

Quando há medição para comparar

$$\text{erro relativo} = \frac{|\,\text{previsto} - \text{medido}\,|}{\text{medido}}$$

O quanto se tolera **depende do uso**, e o erro costuma crescer **na carga alta**.

Nunca sustentar um resultado com uma técnica só.

Fonte: [Jain, 1991], cap. 25, §25.2.

Síntese da aula

Seção	Ideia central	O que levar
2.1 Filas	Filas estão no banco, na impressora compartilhada e no roteador	Queremos estimar tempo de atendimento, espera e nº de clientes
2.2 Fluxo	Filas são sistemas de fluxo: mercadoria, canal, capacidade limitada	$R > C$ é onde a fila nasce; computação é fluxo **não estável**
2.3 Processo	Mercadoria vira **cliente**; canal vira **centro de serviço**	$A(t)$ e $B(x)$, independentes entre si
2.4 Fila única	Variáveis, relações e notação	λ, μ, w, x, s, n, ρ e A/S/m/B/K/SD
2.5 M/M/1	Nascimento e morte: o estado é o nº de usuários; taxas constantes	$p_n = (1-\rho)\rho^n$, e daí U, $E[n]$, $E[s]$, $E[w]$ e $E[n_w]$

As relações para guardar

$$E[n] = E[n_w] + E[n_s] \quad \cdot \quad E[s] = E[w] + E[x] \quad \cdot \quad E[n] = \lambda E[s] \quad \cdot \quad \rho = \lambda/(m\mu) < 1$$

Aviso: Lista de Exercícios 01

Disponível no SIGAA ainda esta semana

- A **Lista 01** será publicada no SIGAA nos próximos dias
- Vocês serão **notificados pelo próprio sistema** — acompanhem o aviso
- Tema: **modelagem** (sistemas de fluxo, variáveis, relações e notação de Kendall)

Prazo de entrega

Até **23:59 do dia que antecede** a data marcada para a Avaliação.

Pontuação

Vale **2,5 pontos** em uma das notas da disciplina.

Sugestão: comecem pela lista logo após esta aula — o conteúdo dela é exatamente o que acabamos de sintetizar.

Próxima aula

Introdução à Simulação e seus Fundamentos

- **Conceitos fundamentais** e terminologia de modelagem e simulação
- **Tipos de modelos**: eventos discretos, contínuos, estocásticos e determinísticos
- **Etapas de um estudo de simulação**: da formulação à validação
- Vantagens, limitações e principais áreas de aplicação

Para a próxima aula: faça a leitura inicial sobre os fundamentos de simulação, iniciaremos a discussão dos conceitos e métodos na aula que vem.

Fonte: [Johnson e Coutinho, 2011].

Referências

[Johnson e Coutinho, 2011] JOHNSON, T. M. S. M.; COUTINHO, M. M. *Avaliação de Desempenho de Sistemas Computacionais*. Rio de Janeiro: LTC, 2011. **(Livro-base desta aula: Parte II, Capítulo 2, seções 2.1 a 2.4 e exercícios da seção 2.6.)**

[Kendall, 1953] KENDALL, D. G. Stochastic processes occurring in the theory of queues and their analysis by the method of the imbedded Markov chain. *The Annals of Mathematical Statistics*, v. 24, n. 3, p. 338–354, 1953.

[Kleinrock, 1976] KLEINROCK, L. *Queueing Systems, Volume 1: Theory*. New York: John Wiley & Sons, 1976. (Referência do livro-base para as deduções.)

[Allen, 1978] ALLEN, A. O. *Probability, Statistics, and Queueing Theory with Computer Science Applications*. New York: Academic Press, 1978.

[Jain, 1991] JAIN, R. *The Art of Computer Systems Performance Analysis*. New York: John Wiley & Sons, 1991.